

PROJET COMBINE : Architecture Web Avancé et Développement Mobile

Gestion des documents et Chat IA fondée sur le RAG

Élément	Valeur
Version	1.0 – document de cadrage fonctionnel et technique
Date	24 août 2026
Auteur	M. Arthur PESSA / Mme Ytembe Therese
Classe	Cycle Ingénieur niveau 4, filière Informatique et Systèmes d'Information
Périmètre	Application mobile iOS et Android, backend, traitement PDF et images

Document de travail destiné à cadrer la conception, le développement, les tests et le déploiement du produit.

1. Résumé exécutif et vision produit

Le projet consiste à concevoir une application mobile de conversation avec un Assistant IA capable de répondre à des questions à partir d'un corpus documentaire fourni par l'utilisateur. Le corpus est constitué principalement de fichiers PDF et d'images ; il peut contenir du texte natif, des scans, des tableaux, des schémas ou des photographies de documents.

La solution s'appuie sur une architecture de Retrieval-Augmented Generation (RAG). Les documents sont ingérés, analysés, segmentés et indexés afin que, lors d'une question, les passages les plus pertinents soient récupérés puis transmis au modèle de langage (LLM). La réponse doit être explicitement reliée à ses preuves : chaque affirmation importante est associée à une ou plusieurs références ouvrant le document, la page et, lorsque c'est possible, l'extrait ou la zone d'image concernée. Cette approche reprend le principe d'une réponse et vérifiable mis en avant par les solutions de recherche documentaire assistée par IA [1] [2].

Le produit doit également permettre de consulter les conversations déjà générées et leurs références sans connexion Internet. Le mode hors ligne ne promet pas nécessairement la génération complète d'une nouvelle réponse ; il garantit prioritairement l'accès au corpus synchronisé, à l'historique, aux réponses sauvegardées et aux citations. Une extension de génération locale pourra être étudiée en option.

2. Contexte, objectifs et périmètre

2.1 Objectifs du projet

- Permettre à un utilisateur d'importer, organiser et interroger un corpus composé de PDF et d'images.
- Fournir des réponses conversationnelles concises, contextualisées et accompagnées de références vérifiables.
- Réduire les réponses non fondées grâce à une politique de réponse limitée aux éléments retrouvés dans les sources.
- Offrir la consultation hors ligne des documents, conversations, réponses et références préalablement synchronisés.
- Préparer une extension de réalité augmentée pour afficher des instructions documentaires contextualisées dans l'environnement réel.

2.2 Périmètre inclus

Inclus dans le MVP	Option
Application mobile iOS/Android	Version desktop dédiée
Import PDF et images depuis fichiers, appareil photo et galerie	Import de vidéos ou pages web
Portail web Angular pour écoles, utilisateurs, rôles et corpus	Application desktop native
OCR des documents numérisés et images	Transcription audio avancée
Indexation hybride texte + vecteurs	Entraînement ou fine-tuning d'un modèle propriétaire
Chat IA avec citations et extraits	Agents autonomes exécutant des actions externes
Historique et consultation hors ligne	Génération locale complète sur tous les appareils
Synchronisation multi-appareils	Collaboration temps réel avancée

2.3 Contraintes

Le projet suppose l'existence d'un service de modèle de langage accessible par API et d'un service d'embeddings compatible avec le traitement multilingue. Les fonctions de génération et d'indexation initiale nécessitent généralement une connexion, tandis que la consultation hors ligne porte sur les contenus déjà téléchargés. Les droits d'utilisation des documents importés restent sous la responsabilité de l'utilisateur ou de l'organisation qui déploie la solution.

3. Utilisateurs et parcours principaux

Profil	Besoins principaux	Critère de valeur
Etudiant	Comprendre un corpus, poser des questions, vérifier les passages cités	Gain de temps et traçabilité des réponses
Personnel	Interroger des procédures, normes ou manuels internes	Réponse opérationnelle et fiable
Technicien terrain	Consulter des instructions sur site, parfois sans réseau	Accès rapide aux étapes et avertissements
Administrateur / responsable contenu	Gérer les corpus, droits, versions et métriques	Maîtrise de la qualité et de la sécurité

3.1 Parcours nominal : question-réponse sourcée

1. L'utilisateur crée un espace documentaire et importe un ou plusieurs PDF ou images.
2. Le système affiche l'état de traitement : en attente, OCR, segmentation, indexation, disponible ou erreur.
3. L'utilisateur ouvre une conversation et saisit une question en langage naturel.
4. Le moteur récupère les passages pertinents, génère une réponse et associe les citations aux affirmations.
5. L'utilisateur consulte la réponse, ouvre une référence, visualise l'extrait source et peut enregistrer ou partager la réponse.

3.2 Parcours hors ligne

Lorsque l'appareil est hors connexion, l'utilisateur voit clairement l'état du réseau et le périmètre disponible. Il peut ouvrir les documents marqués comme disponibles hors ligne, parcourir les conversations sauvegardées, lire les réponses précédentes et accéder aux références. Une nouvelle question peut être enregistrée dans une file d'attente locale ; si un modèle local est ultérieurement retenu, le système pourra proposer une réponse locale clairement signalée comme telle.

4. Fonctionnalités attendues

4.1 Gestion des espaces et sources

Fonctionnalité	Description
Créer un espace	Nom, description, langue principale, paramètres de confidentialité.
Importer des PDF	Sélection depuis le stockage, partage système ou téléchargement contrôlé.
Importer des images	Galerie et appareil photo ; formats JPEG, PNG, HEIC à préciser.
OCR	Extraction du texte et conservation des coordonnées des blocs reconnus.
Métadonnées	Titre, auteur, date, tags, version et statut de traitement.
Supprimer / remplacer	Suppression logique

4.2 Conversation avec l'Assistant IA

Fonctionnalité	Exigence d'acceptation
Poser une question	L'utilisateur peut envoyer une question en texte et consulter l'état de génération.
Contexte conversationnel	Les tours précédents sont pris en compte dans les limites configurées. De plus les réponses concernent uniquement les écoles pour lesquels l'utilisateur est rattaché
Réponse avec citations	Chaque réponse affiche les références utilisées sous forme de marqueurs lisibles.
Extrait source	Un clic ouvre le document à la page ou zone concernée, avec surlignage si possible.
Réponse insuffisamment étayée	L'assistant indique qu'il ne trouve pas de preuve suffisante au lieu d'inventer.
Actions sur réponse	Copier, enregistrer, partager et signaler une réponse incorrecte.

4.3 Historique et références

Chaque message généré doit conserver la question, la réponse, la date, le modèle utilisé, les paramètres utiles, les passages récupérés et les références affichées. La fiche de référence doit présenter le nom du document, son numéro de version, la page ou l'identifiant de l'image, l'extrait textuel. Les références doivent rester consultables si l'utilisateur passe hors ligne, sous réserve que la source correspondante ait été synchronisée.

4.4 Recherche dans le corpus

Une recherche directe, indépendante du chat, doit permettre de retrouver un document ou un passage par mots-clés, filtres et similarité sémantique. Le moteur privilégiera une recherche hybride combinant recherche lexicale et vectorielle, avec réordonnement des résultats lorsque cela améliore la pertinence [1].

4.5 Portail web d'administration

Un portail web développé complète l'application mobile. Il est destiné aux administrateurs de la plateforme, responsables d'écoles et gestionnaires de contenu. Le portail centralise la création des écoles, l'administration des comptes, l'affectation des rôles, la définition des droits documentaires et le suivi des conversations ou traitements, sans exposer les fonctions d'administration aux utilisateurs mobiles.

Fonctionnalité web	Description
Tableau de bord	Vue synthétique des écoles, utilisateurs, corpus, traitements et alertes.
Gestion des écoles	Créer, modifier, désactiver une école ; gérer ses paramètres, responsables et espaces documentaires.
Gestion des utilisateurs	Inviter, rechercher, modifier, suspendre et réactiver un utilisateur.
Gestion des rôles	Créer ou modifier des rôles et leur associer des permissions et périmètres documentaires.
Affectations	Associer un utilisateur à une école, ou un groupe et à un ou plusieurs rôles.
Gestion documentaire	Associer des sources à une école, un rôle, une classe ou un groupe ; gérer les versions.
Audit	Intégrer le principe de non répudiation.

4.6 Authentification et gestion des comptes

L'authentification principale sera réalisée via le compte Google (Institutionnel) de l'utilisateur, au moyen d'un flux OAuth 2.0 / OpenID Connect. Le portail et l'application mobile doivent utiliser le même fournisseur d'identité et le même référentiel de comptes. Après la première connexion, le backend vérifie le jeton, rapproche l'identité Google d'un compte interne et applique l'état du compte, l'école, les rôles et les autorisations. Le terme « Google Mail » est donc traité comme une authentification avec un compte Google, **sans stockage du mot de passe par l'application**. NB : La création des comptes Administrateurs nécessitent un email (gmail) et un mot de passe.

- Connexion par bouton « Se connecter avec Google » sur web et mobile.
- Vérification serveur de l'identité, de l'émetteur, de l'audience et de l'expiration du jeton.
- Possibilité de restreindre l'accès aux domaines Google Workspace autorisés d'une école.
- Création du profil interne : aucune autorisation documentaire ne doit être accordée uniquement parce qu'un compte Google est valide.
- Déconnexion, révocation de session, gestion des comptes suspendus et traçabilité des connexions.

4.7 Autorisation documentaire selon le rôle

Les utilisateurs de l'application mobile ne doivent recevoir que des réponses produites à partir des documents associés à leur périmètre d'autorisation. Avant toute récupération RAG, le backend calcule les filtres d'accès à partir de l'identité authentifiée, de l'école, des groupes et des rôles actifs. Ces filtres sont appliqués au niveau de la recherche et non uniquement après génération, afin d'éviter qu'un passage non autorisé n'entre dans le contexte du modèle.

Exemple de rôle	Périmètre documentaire possible	Exemple de réponse autorisée
Administrateur plateforme	Toutes les écoles et tous les espaces selon délégation	Référentiel global ou rapports d'administration
Administrateur école	Une école et ses espaces documentaires	Règlement interne, procédures et documents de l'école
Personnel	École(s) affectée(s)	Cours, consignes et ressources de ses classes
Élève / personnel	Documents explicitement publiés pour son école ou son groupe	Réponse fondée uniquement sur les supports accessibles
Parent / invite	Documents partagés explicitement	Informations publiques ou documents autorisés

Une modification de rôle ou d'association doit invalider les caches concernés et être répercutée lors de la prochaine synchronisation mobile. Les réponses et références enregistrées doivent conserver le contexte d'autorisation et la version des documents au moment de leur génération. Si un document devient inaccessible, l'historique peut conserver la réponse selon la politique de rétention, mais doit signaler que la source n'est plus disponible.

5. Architecture fonctionnelle et technique

5.1 Vue logique

Couche	Composants proposés	Responsabilités
Application web	Framework Angular 21	Administration des écoles, utilisateurs, rôles, droits et corpus, Import
Mobile	iOS/Android, UI conversationnelle, stockage local (SQLite), synchronisation. Framework React Native 0.87	Chat, visualisation, cache, hors ligne, synchronisation
Backend	Framework Node.js (LTS version) ou Nest.js (11.2.1)	Authentification, écoles, utilisateurs, rôles, espaces, conversations, fichiers, synchronisation, API, contrôle d'accès
Pipeline documentaire	Détection type, OCR, parsing, segmentation	Transformer les sources en unités indexables
Recherche	Index lexical, base vectorielle, reranker	Récupérer les passages pertinents
Génération	LLM, prompt système, garde-fous	Produire une réponse fidèle et citée
Observabilité	Logs, métriques, traces, feedback	Mesurer qualité, coûts, latence et erreurs

5.2 Pipeline RAG cible

- Ingestion : validation du fichier, antivirus, empreinte, stockage objet et création d'une version.
- Prétraitement : extraction du texte natif, OCR si nécessaire, détection de la langue et identification des pages ou zones.
- Segmentation : découpage en passages avec chevauchement contrôlé, conservation des métadonnées de provenance.
- Vectorisation : création d'embeddings textuels ; extension possible aux embeddings multimodaux pour les images [1].
- Récupération : recherche hybride, filtrage par espace et version, puis réordonnancement des passages.
- Génération : prompt imposant l'utilisation des passages fournis, citations et formulation d'incertitude.
- Post-traitement : validation des citations, détection de références absentes, formatage de la réponse et enregistrement.

6. Exigences non fonctionnelles

Domaine	Exigence cible
Performance	Afficher l'interface en moins de 2 secondes après ouverture ; viser une première réponse en moins de 8 secondes dans des conditions nominales.
Disponibilité	Le service en ligne doit être supervisé et disposer d'une stratégie de reprise documentée.
Scalabilité	Séparer les traitements asynchrones d'ingestion/OCR de l'API conversationnelle.
Accessibilité	Respecter les principes WCAG applicables au mobile : contraste, tailles dynamiques, lecteur d'écran et navigation clavier externe.
Déploiement	Déployer l'application mobile sur PlayStore.
Internationalisation	Prévoir le français en première langue et l'architecture pour d'autres langues.
Conception	Architecture orientée composants, modèle de patrons de conception respecté

7. Mode hors ligne et synchronisation

7.1 Périmètre hors ligne

Disponible hors ligne	Dépendant d'Internet dans le MVP
Documents et images explicitement téléchargés	Import distant et OCR serveur
Conversations et réponses sauvegardées	Génération via LLM distant
Références et extraits associés	Réindexation globale du corpus
Recherche locale dans les contenus synchronisés	Partage vers un espace distant
File d'attente des questions à synchroniser	Mise à jour de modèles et paramètres serveur

7.2 Règles de synchronisation

- L'utilisateur choisit les espaces et sources disponibles hors ligne, avec estimation de la taille occupée.
- La synchronisation est différentielle et reprend après interruption.
- L'interface ne doit jamais présenter comme « hors ligne » une réponse dont les preuves ne sont pas présentes localement.

8. Réalité augmentée – fonctionnalité (bonus)

Le cas d'usage recommandé est une ****assistance documentaire contextualisée sur un équipement ou un lieu****. L'utilisateur pointe la caméra vers une machine, un panneau, une installation, un composant ou un objet identifié. L'application reconnaît le contexte, interroge le corpus documentaire correspondant, puis superpose à la vue réelle des étapes de procédure, des avertissements de sécurité, des repères visuels et un accès direct aux extraits sources. Cette approche est cohérente avec le rôle de l'AR mobile : intégrer des informations numériques dans l'environnement réel au moyen de la caméra et des capteurs [3]. Elle s'inspire également des scénarios d'assistance terrain où des guides, schémas et consignes sont superposés à l'équipement [4].

8.1 Scénario détaillé

13. L'utilisateur sélectionne un espace documentaire et active le mode « Assistance AR ».
14. La caméra détecte un marqueur QR/image ou tente une reconnaissance sans marqueur, selon le niveau de maturité retenu.
15. Le système associe l'objet à une fiche ou à un ensemble de documents versionnés.
16. Le RAG récupère les passages correspondant à la demande ou à l'étape sélectionnée.
17. L'application affiche des repères 2D/3D, une consigne courte, un avertissement éventuel et un bouton « Voir la preuve » ouvrant la page ou la zone source.
18. L'utilisateur peut confirmer une étape, prendre une photo annotée et enregistrer l'intervention dans l'historique.

9. Critères d'acceptation fonctionnels

- Un PDF natif, un PDF scanné et une image contenant du texte peuvent être importés et identifiés.
- Une question dont la réponse figure dans le corpus produit une réponse accompagnée d'au moins une référence correcte.
- Une question absente du corpus déclenche une formulation d'incertitude et n'invente pas de référence.
- L'ouverture d'une citation affiche le bon document et la bonne page ou zone, lorsque la précision est disponible.
- Après synchronisation, un utilisateur peut consulter hors ligne une réponse et toutes ses références téléchargées.
- La suppression d'une source empêche qu'elle soit récupérée dans les nouvelles réponses.

10. Planning et livrables

- Présentation des projets suivant la période **du 04 au 08 janvier 2027**. La présence de tous est obligatoire, l'application mobile (Android) est déployée sur PlayStore.
- La gestion du projet et code source sont hébergés sur Github.
- **L'application stricte des modèles d'architecture de conception (MVC ou HMVC, MVVM and Frontend Architecture).**
- **L'application stricte de l'architecture orientée composant**

11. Références

[1] Google Cloud, « What is Retrieval-Augmented Generation (RAG)? », <https://cloud.google.com/use-cases/retrieval-augmented-generation>

[2] Google, « NotebookLM / Gemini Notebook – Understand Anything », <https://notebooklm.google/>

[3] IBM, « What is augmented reality? », <https://www.ibm.com/think/topics/augmented-reality>

[4] Salesforce, « What Is Augmented Reality in Field Service — and How it Can Transform Your Business », <https://www.salesforce.com/service/field-service-management/what-is-augmented-reality-in-field-service/>